Kubernetes 工作负载

总：Workloads

```
#获取控制台访问令牌
kubectl -n kubernetes-dashboard describe secret $(kubectl -n kubernetes-dashboard get secret | grep admin-user | awk '{print $1}')
```

> 什么是工作负载（Workloads）
>
> - 工作负载是运行在 Kubernetes 上的一个应用程序。
> - 一个应用很复杂，可能由单个组件或者多个组件共同完成。无论怎样我们可以用一组Pod来表示一个应用，也就是一个工作负载
> - Pod又是一组容器（Containers）
> - 所以关系又像是这样
>   - 工作负载（Workloads）控制一组Pod
>   - Pod控制一组容器（Containers）
>   - 比如Deploy（工作负载） 3个副本的nginx（3个Pod），每个nginx里面是真正的nginx容器（container）

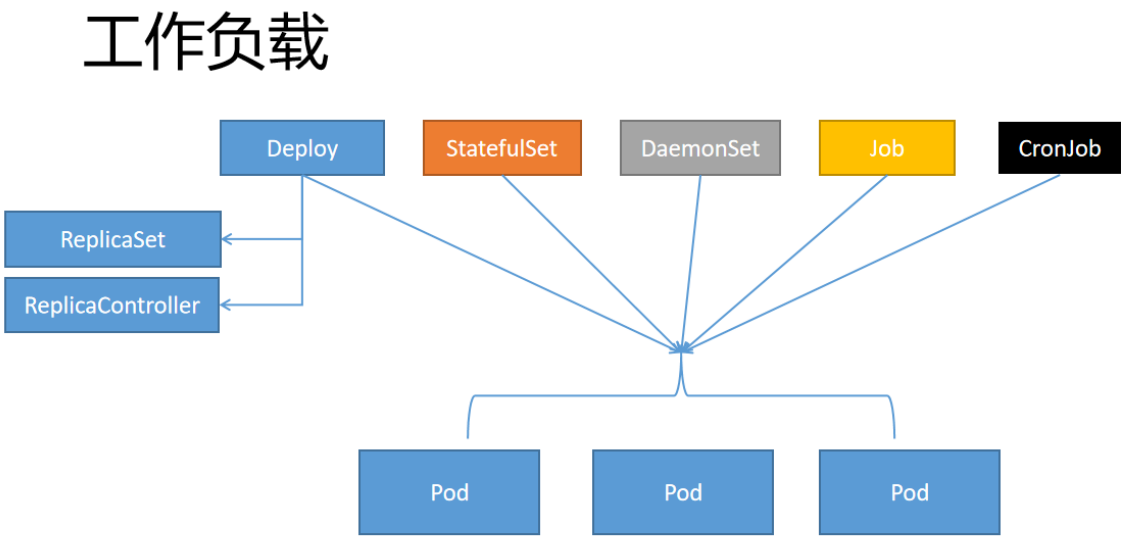

工作负载能让Pod能拥有自恢复能力。

会写Pod。研究不同的工作负载怎么控制Pod的行为

一、Pod

1、什么是Pod

- *Pod* 是一组（一个或多个） **容器（docker容器）** 的集合 （就像在豌豆荚中）；这些容器共享存储、网络、以及怎样运行这些容器的声明。
- 
- 我们一般不直接创建Pod，而是创建一些工作负载由他们来创建Pod
- Pod的形式
  - Pod对容器有自恢复能力（Pod自动重启失败的容器）
  - Pod自己不能恢复自己，Pod被删除就真的没了（100，MySQL、Redis、Order）还是希望k8s集群能自己在其他地方再启动这个Pod
  - 单容器Pod
  - 多容器协同Pod。我们可以把另外的容器称为 `SideCar（为应用赋能）`
  - Pod 天生地为其成员容器提供了两种共享资源： **网络** 和 **存储**。
- 一个Pod由一个**Pause容器**设置好整个Pod里面所有容器的网络、名称空间等信息
- systemctl status可以观测到。Pod和容器进程关系
  - kubelet启动一个Pod，准备两个容器，一个是Pod声明的应用容器（nginx），另外一个是Pause。Pause给当前应用容器设置好网络空间各种的。
  -

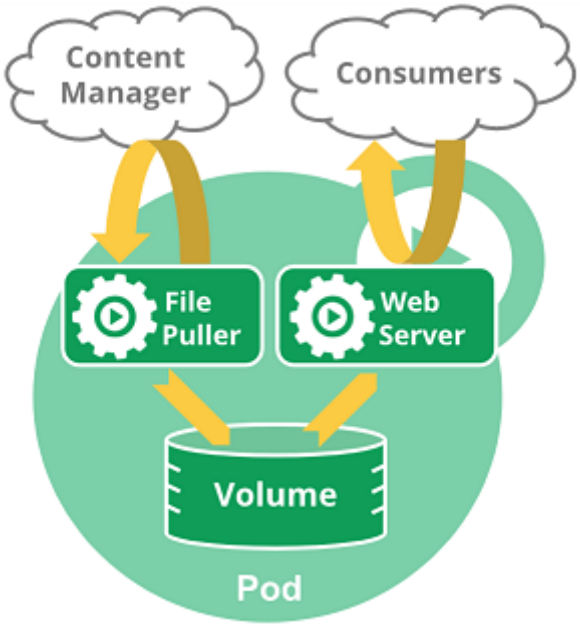

> 编写yaml测试：多容器协同

2、Pod使用

- 可以编写deploy等各种工作负载的yaml文件，最终创建出pod，也可以直接创建
- Pod的模板如下
-

```yaml
# 这里是 Pod 模版
apiVersion: v1
kind: Pod
metadata:
  name: my-pod
spec:
  containers:
  - name: hello
    image: busybox
    command: ['sh', '-c', 'echo "Hello, Kubernetes!" && sleep 3600']
  restartPolicy: OnFailure
# 以上为 Pod 模版
```

3、Pod生命周期

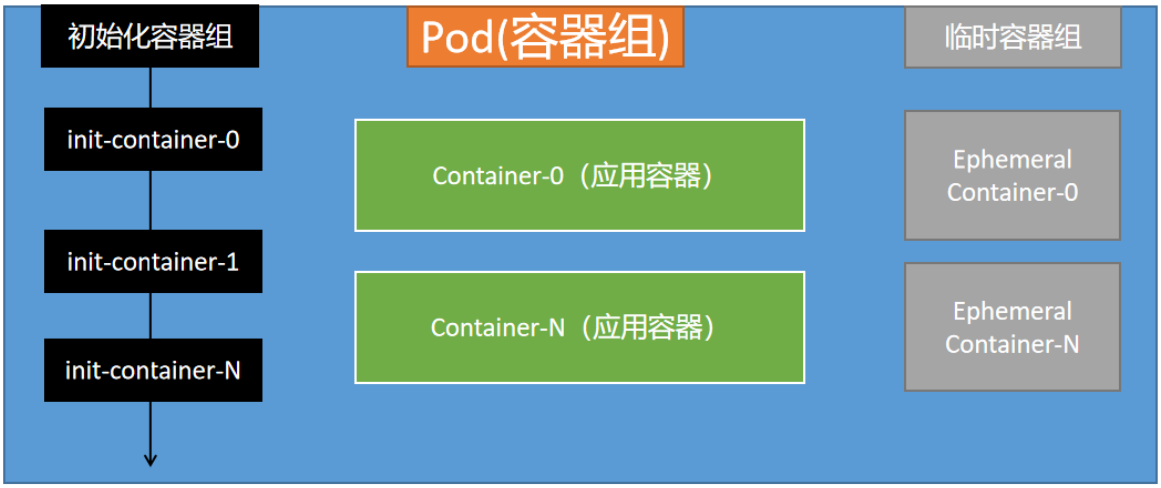

- Pod启动，会先**依次**执行所有初始化容器，有一个失败，则Pod不能启动
- 接下来**启动所有的应用容器**（每一个应用容器都必须能一直运行起来），Pod开始正式工作，一个启动失败就会**尝试重启Pod内的这个容器**，Pod只要是NotReady，Pod就不对外提供服务了

> 编写yaml测试生命周期
>
> - 应用容器生命周期钩子
> - 初始化容器（也可以有钩子）

```
my-nginx666                  1/1     Running    0          2d
pod-life-02                  0/2     Init:0/1   0          5s
```

临时容器：线上排错。

有些容器基础镜像。线上没法排错。使用临时容器进入这个Pod。临时容器共享了Pod的所有。临时容器有Debug的一些命令，拍错完成以后，只要exit退出容器，临时容器自动删除

Java：dump， jre 50mb。jdk 150mb

jre 50mb。: jdk作为临时容器

> 临时容器需要开启特性门控 --feature-gates="EphemeralContainers=true"
>
> 在所有组件，api-server、kubelet、scheduler、controller-manager都得配置

1.21.0： 生产环境 .5

使用临时容器的步骤：

1、声明一个临时容器。准备好json文件

```
{
    "apiVersion": "v1",
    "kind": "EphemeralContainers",
    "metadata": {
            "name": "my-nginx666" //指定Pod的名字
    },
    "ephemeralContainers": [{
        "command": [
```

```
            "sh"
        ],
        "image": "busybox",  //jre的需要jdk来调试
        "imagePullPolicy": "IfNotPresent",
        "name": "debugger",
        "stdin": true,
        "tty": true,
        "terminationMessagePolicy": "File"
    }]
}
```

2、使用临时容器，应用一下即可

```
kubectl replace --raw /api/v1/namespaces/default/pods/my-nginx666【pod名】/ephemeralcontainers  -f ec.json
```

4、静态Pod

在 **/etc/kubernetes/manifests** 位置放的所有Pod.yaml文件，机器启动kubelet自己就把他启动起来。

静态Pod一直守护在他的这个机器上

5、 Probe 探针机制（健康检查机制）

- 每个容器三种探针（Probe）
  - **启动探针**（后来才加的） **一次性成功探针。** 只要启动成功了
    - kubelet 使用启动探针，来检测应用是否已经启动。如果启动就可以进行后续的探测检查。慢容器一定指定启动探针。一直在等待启动
    - **启动探针 成功以后就不用了，剩下存活探针和就绪探针持续运行**
  - 存活探针
    - kubelet 使用存活探针，来检测容器是否正常存活。（有些容器可能产生死锁【应用程序在运行，但是无法继续执行后面的步骤】），如果检测失败就会**重新启动这个容器**
    - initialDelaySeconds： 3600（长了导致可能应用一段时间不可用） 5（短了陷入无限启动循环）
  - 就绪探针
    - kubelet 使用就绪探针，来检测容器是否准备**好了可以接收流量**。当一个 Pod 内的所有容器都准备好了，才能把这个 Pod 看作就绪了。用途就是：Service后端负载均衡多个Pod，如果某个Pod还没就绪，就会从service负载均衡里面剔除
  - 谁利用这些探针探测
    - kubelet会主动按照配置给Pod里面的所有容器发送响应的探测请求

- Probe配置项

- `initialDelaySeconds`：容器启动后要等待多少秒后存活和就绪探测器才被初始化，默认是 0 秒，最小值是 0。这是针对以前没有
- `periodSeconds`：执行探测的时间间隔（单位是秒）。默认是 10 秒。**最小值是 1**。
- `successThreshold`：探测器在失败后，被视为成功的最小连续成功数。**默认值是 1**。
  - 存活和启动探针的这个值必须是 1。最小值是 1。
- `failureThreshold`：当探测失败时，Kubernetes 的重试次数。 存活探测情况下的放弃就意味着重新启动容器。 就绪探测情况下的放弃 Pod 会被打上未就绪的标签。**默认值是 3**。最小值是 1。
- `timeoutSeconds`：探测的超时后等待多少秒。**默认值是 1 秒**。最小值是 1。

https://kubernetes.io/zh/docs/tasks/configure-pod-container/configure-liveness-readiness-startup-probes/#configure-probes

```
    exec、httpGet、tcpSocket 【那种方式探测】



    failureThreshold



    initialDelaySeconds

    periodSeconds

    successThreshold



    terminationGracePeriodSeconds

    timeoutSeconds   <integer>

```

> 编写yaml测试探针机制

```yaml
apiVersion: v1
kind: Pod
metadata:
  name: "nginx-start-probe02"
  namespace: default
  labels:
    app: "nginx-start-probe02"
spec:
  volumes:
  - name: nginx-vol
    hostPath:
      path: /app
  - name: nginx-html
    hostPath:
      path: /html
  containers:
```

```yaml
    - name: nginx
      image: "nginx"
      ports:
      - containerPort: 80
      startupProbe:
        exec:
          command:  ["/bin/sh","-c","cat /app/abc"]  ## 返回不是0，那就是探测失败
        # initialDelaySeconds: 20 ## 指定的这个秒以后才执行探测
        periodSeconds: 5  ## 每隔几秒来运行这个
        timeoutSeconds: 5  ##探测超时，到了超时时间探测还没返回结果说明失败
        successThreshold: 1 ## 成功阈值，连续几次成才算成功
        failureThreshold: 3 ## 失败阈值，连续几次失败才算真失败
      volumeMounts:
      - name: nginx-vol
        mountPath: /app
      - name: nginx-html
        mountPath: /usr/share/nginx/html
      livenessProbe:   ## nginx容器有没有 /abc.html，就绪探针
        # httpGet:
        #   host: 127.0.0.1
        #   path: /abc.html
        #   port: 80
        #   scheme: HTTP
        # periodSeconds: 5  ## 每隔几秒来运行这个
        # successThreshold: 1 ## 成功阈值，连续几次成才算成功
        # failureThreshold: 5 ## 失败阈值，连续几次失败才算真失败
        exec:
          command:  ["/bin/sh","-c","cat /usr/share/nginx/html/abc.html"]  ## 返回不是0，那就是探测失败
        # initialDelaySeconds: 20 ## 指定的这个秒以后才执行探测
        periodSeconds: 5  ## 每隔几秒来运行这个
        timeoutSeconds: 5  ##探测超时，到了超时时间探测还没返回结果说明失败
        successThreshold: 1 ## 成功阈值，连续几次成才算成功
        failureThreshold: 3 ## 失败阈值，连续几次失败才算真失败
      readinessProbe: ##就绪检测，都是http
        httpGet:
          # host: 127.0.0.1  ###不行
          path: /abc.html  ## 给容器发请求
          port: 80
          scheme: HTTP ## 返回不是0，那就是探测失败
        initialDelaySeconds: 2 ## 指定的这个秒以后才执行探测
        periodSeconds: 5  ## 每隔几秒来运行这个
        timeoutSeconds: 5  ##探测超时，到了超时时间探测还没返回结果说明失败
        successThreshold: 3 ## 成功阈值，连续几次成才算成功
        failureThreshold: 5 ## 失败阈值，连续几次失败才算真失败

      # livenessProbe:
      #   exec: ["/bin/sh","-c","sleep 30;abc "]  ## 返回不是0，那就是探测失败
      #   initialDelaySeconds: 20 ## 指定的这个秒以后才执行探测
      #   periodSeconds: 5  ## 每隔几秒来运行这个
      #   timeoutSeconds: 5  ##探测超时，到了超时时间探测还没返回结果说明失败
      #   successThreshold: 5 ## 成功阈值，连续几次成才算成功
      #   failureThreshold: 5 ## 失败阈值，连续几次失败才算真失败
```

微服务。 /health

K8S检查当前应用的状态；connection refuse；

SpringBoot 优雅停机：gracefulShowdown: true

pod.spec.**terminationGracePeriodSeconds** = 30s 优雅停机；给一个缓冲时间

健康检查+优雅停机 = 0宕机

start完成以后，liveness和readness并存。 liveness失败导致重启。readness失败导致不给Service负载均衡网络中加，不接受流量。 kubectl exec -it 就进不去。Kubectl describe 看看咋了。

二、Deployment

1、什么是Deployment

- 一个 *Deployment* 为 **Pods** 和 **ReplicaSets** 提供声明式的更新能力。
- 你负责描述 Deployment 中的 *目标状态*，而 Deployment **控制器（Controller）** 以受控速率更改**实际状态**， 使其变为**期望状态**；控制循环。 for(){ xxx controller.spec()}
- 不要管理 Deployment 所拥有的 ReplicaSet
- 我们部署一个应用一般不直接写Pod，而是部署一个Deployment
- Deploy编写规约 **https://kubernetes.io/zh/docs/concepts/workloads/controllers/deployment/#writing-a-deployment-spec**

2、Deployment创建

- 基本格式
  - `.metadata.name` 指定deploy名字
  - `replicas` 指定副本数量
  - `selector` 指定匹配的Pod模板。
  - `template` 声明一个Pod模板

> 编写一个Deployment的yaml
>
> 赋予Pod自愈和故障转移能力。

- 在检查集群中的 Deployment 时，所显示的字段有：

    - `NAME` 列出了集群中 Deployment 的名称。
    - `READY` 显示应用程序的可用的 *副本* 数。显示的模式是“就绪个数/期望个数”。
    - `UP-TO-DATE` 显示为了达到期望状态已经更新的副本数。
    - `AVAILABLE` 显示应用可供用户使用的副本数。
    - `AGE` 显示应用程序运行的时间。
- ReplicaSet 输出中包含以下字段：
    - `NAME` 列出名字空间中 ReplicaSet 的名称；
    - `DESIRED` 显示应用的期望副本个数，即在创建 Deployment 时所定义的值。 此为期望状态；
    - `CURRENT` 显示当前运行状态中的副本个数；
    - `READY` 显示应用中有多少副本可以为用户提供服务；
    - `AGE` 显示应用已经运行的时间长度。
    - 注意：ReplicaSet 的名称始终被格式化为 `[Deployment名称]-[随机字符串]` 。 其中的随机字符串是使用 pod-template-hash 作为种子随机生成的。

> 一个Deploy产生三个
>
> - Deployment资源
> - replicaset资源
> - Pod资源
>
> Deployment控制RS，RS控制Pod的副本数
>
> ReplicaSet： 只提供了副本数量的控制功能
>
> Deployment： 每部署一个新版本就会创建一个新的副本集，利用他记录状态，回滚也是直接让指定的rs生效
>
> --- rs1： 4 abc
>
> --- rs2: 4 def
>
> --- rsN: 4 eee
>
> nginx=111 nginx:v1=2222 nginx:v2=3333

3、Deployment 更新机制

- 仅当 Deployment Pod 模板（即 `.spec.template`）发生改变时，例如**模板的标签或容器镜像被更新， 才会触发 Deployment 上线。 其他更新（如对 Deployment 执行扩缩容的操作）不会触发上线动作。**
- **上线动作 原理： 创建新的rs，准备就绪后，替换旧的rs（此时不会删除，因为 `revisionHistoryLimit` 指定了保留几个版本）**
- 常用的kubectl 命令

```
################更新###################################
#kubectl  set image  deployment资源名  容器名=镜像名
kubectl set image deployment.apps/nginx-deployment php-redis=tomcat:8 --record
## yaml提取可更新的关键所有字段计算的hash。
web---- /hello
postman   aservice- /hello

#或者直接修改定义也行
```

```
kubectl edit deployment.v1.apps/nginx-deployment
#查看状态
kubectl rollout status deployment.v1.apps/nginx-deployment

################查看历史并回滚#####################################
#查看更新历史-看看我们设置的历史总记录数是否生效了
kubectl rollout history deployment.v1.apps/nginx-deployment
#回滚
kubectl rollout undo deployment.v1.apps/nginx-deployment --to-revision=2

###############累计更新##############
#暂停记录版本
kubectl rollout pause deployment.v1.apps/nginx-deployment
#多次更新操作。
##比如更新了资源限制
kubectl set resources deployment.v1.apps/nginx-deployment -c=nginx --
limits=cpu=200m,memory=512Mi
##比如更新了镜像版本
kubectl set image deployment.apps/nginx-deployment php-redis=tomcat:8
##在继续操作多次
##看看历史版本有没有记录变化
kubectl rollout history deployment.v1.apps/nginx-deployment
#让多次累计生效
kubectl rollout resume deployment.v1.apps/nginx-deployment
```

1、*比例缩放（Proportional Scaling）*

maxSurge（最大增量）：除当前数量外还要添加多少个实例。

maxUnavailable（最大不可用量）：滚动更新过程中的不可用实例数。

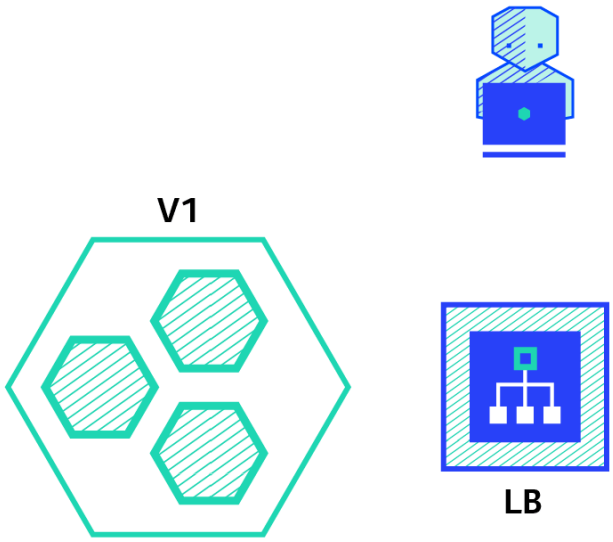

2、 *HPA（动态扩缩容）*

概念： https://kubernetes.io/zh/docs/tasks/run-application/horizontal-pod-autoscale/#scaling-policies

实战： https://kubernetes.io/zh/docs/tasks/run-application/horizontal-pod-autoscale-walkthrough/

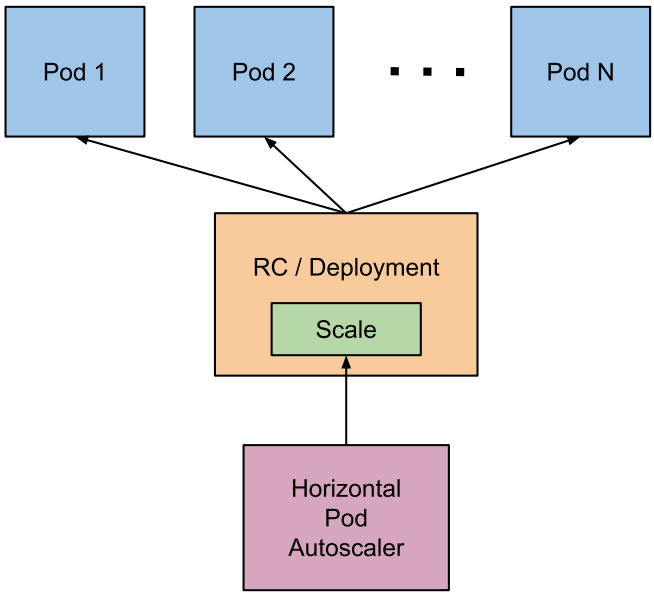

- 需要先安装metrics-server

https://github.com/kubernetes-sigs/metrics-server

- 安装步骤

```yaml
apiVersion: v1
kind: ServiceAccount
metadata:
  labels:
    k8s-app: metrics-server
  name: metrics-server
  namespace: kube-system
---
apiVersion: rbac.authorization.k8s.io/v1
kind: ClusterRole
metadata:
  labels:
    k8s-app: metrics-server
    rbac.authorization.k8s.io/aggregate-to-admin: "true"
    rbac.authorization.k8s.io/aggregate-to-edit: "true"
    rbac.authorization.k8s.io/aggregate-to-view: "true"
  name: system:aggregated-metrics-reader
rules:
```

```yaml
- apiGroups:
  - metrics.k8s.io
  resources:
  - pods
  - nodes
  verbs:
  - get
  - list
  - watch
---
apiVersion: rbac.authorization.k8s.io/v1
kind: ClusterRole
metadata:
  labels:
    k8s-app: metrics-server
  name: system:metrics-server
rules:
- apiGroups:
  - ""
  resources:
  - pods
  - nodes
  - nodes/stats
  - namespaces
  - configmaps
  verbs:
  - get
  - list
  - watch
---
apiVersion: rbac.authorization.k8s.io/v1
kind: RoleBinding
metadata:
  labels:
    k8s-app: metrics-server
  name: metrics-server-auth-reader
  namespace: kube-system
roleRef:
  apiGroup: rbac.authorization.k8s.io
  kind: Role
  name: extension-apiserver-authentication-reader
subjects:
- kind: ServiceAccount
  name: metrics-server
  namespace: kube-system
---
apiVersion: rbac.authorization.k8s.io/v1
kind: ClusterRoleBinding
metadata:
  labels:
    k8s-app: metrics-server
  name: metrics-server:system:auth-delegator
roleRef:
  apiGroup: rbac.authorization.k8s.io
  kind: ClusterRole
  name: system:auth-delegator
subjects:
- kind: ServiceAccount
```

```yaml
    name: metrics-server
    namespace: kube-system
  ---
  apiVersion: rbac.authorization.k8s.io/v1
  kind: ClusterRoleBinding
  metadata:
    labels:
      k8s-app: metrics-server
    name: system:metrics-server
  roleRef:
    apiGroup: rbac.authorization.k8s.io
    kind: ClusterRole
    name: system:metrics-server
  subjects:
  - kind: ServiceAccount
    name: metrics-server
    namespace: kube-system
  ---
  apiVersion: v1
  kind: Service
  metadata:
    labels:
      k8s-app: metrics-server
    name: metrics-server
    namespace: kube-system
  spec:
    ports:
    - name: https
      port: 443
      protocol: TCP
      targetPort: https
    selector:
      k8s-app: metrics-server
  ---
  apiVersion: apps/v1
  kind: Deployment
  metadata:
    labels:
      k8s-app: metrics-server
    name: metrics-server
    namespace: kube-system
  spec:
    selector:
      matchLabels:
        k8s-app: metrics-server
    strategy:
      rollingUpdate:
        maxUnavailable: 0
    template:
      metadata:
        labels:
          k8s-app: metrics-server
      spec:
        containers:
        - args:
          - --cert-dir=/tmp
          - --kubelet-insecure-tls
          - --secure-port=4443
```

```
        - --kubelet-preferred-address-types=InternalIP,ExternalIP,Hostname
        - --kubelet-use-node-status-port
        image: registry.cn-hangzhou.aliyuncs.com/lfy_k8s_images/metrics-server:v0.4.3
        imagePullPolicy: IfNotPresent
        livenessProbe:
          failureThreshold: 3
          httpGet:
            path: /livez
            port: https
            scheme: HTTPS
          periodSeconds: 10
        name: metrics-server
        ports:
        - containerPort: 4443
          name: https
          protocol: TCP
        readinessProbe:
          failureThreshold: 3
          httpGet:
            path: /readyz
            port: https
            scheme: HTTPS
          periodSeconds: 10
        securityContext:
          readOnlyRootFilesystem: true
          runAsNonRoot: true
          runAsUser: 1000
        volumeMounts:
        - mountPath: /tmp
          name: tmp-dir
      nodeSelector:
        kubernetes.io/os: linux
      priorityClassName: system-cluster-critical
      serviceAccountName: metrics-server
      volumes:
      - emptyDir: {}
        name: tmp-dir
---
apiVersion: apiregistration.k8s.io/v1
kind: APIService
metadata:
  labels:
    k8s-app: metrics-server
  name: v1beta1.metrics.k8s.io
spec:
  group: metrics.k8s.io
  groupPriorityMinimum: 100
  insecureSkipTLSVerify: true
  service:
    name: metrics-server
    namespace: kube-system
  version: v1beta1
  versionPriority: 100

```

- kubectl apply 即可、

    - 全部runnning 用
        - kubectl top nodes --use-protocol-buffers
        - kubectl top pods --use-protocol-buffers
- 配置hpa测试

```yaml
### 测试镜像 registry.cn-hangzhou.aliyuncs.com/lfy_k8s_images/php-hpa:latest

##应用的yaml已经做好
apiVersion: v1
kind: Service
metadata:
  name: php-apache
spec:
  ports:
  - port: 80
    protocol: TCP
    targetPort: 80
  selector:
    run: php-apache
---
apiVersion: apps/v1
kind: Deployment
metadata:
  labels:
    run: php-apache
  name: php-apache
spec:
  replicas: 1
  selector:
    matchLabels:
      run: php-apache
  template:
    metadata:
      creationTimestamp: null
      labels:
        run: php-apache
    spec:
      containers:
      - image: registry.cn-hangzhou.aliyuncs.com/lfy_k8s_images/php-hpa:latest
        name: php-apache
        ports:
        - containerPort: 80
        resources:
          requests:
            cpu: 200m

##hpa配置 hpa.yaml
apiVersion: autoscaling/v1
kind: HorizontalPodAutoscaler
metadata:
  name: php-apache
spec:
  maxReplicas: 10
  minReplicas: 1
  scaleTargetRef:
    apiVersion: apps/v1
    kind: Deployment
```

```
      name: php-apache
    targetCPUUtilizationPercentage: 50

#3、进行压力测试
kubectl run -i --tty load-generator --image=busybox /bin/sh

#回车然后敲下面的命令
 kubectl run -i --tty load-generator --rm --image=busybox --restart=Never --
/bin/sh -c "while sleep 0.01; do wget -q -O- http://php-apache; done"
```

3、 *Canary（金丝雀部署）*

1、蓝绿部署VS金丝雀部署

> 蓝绿部署

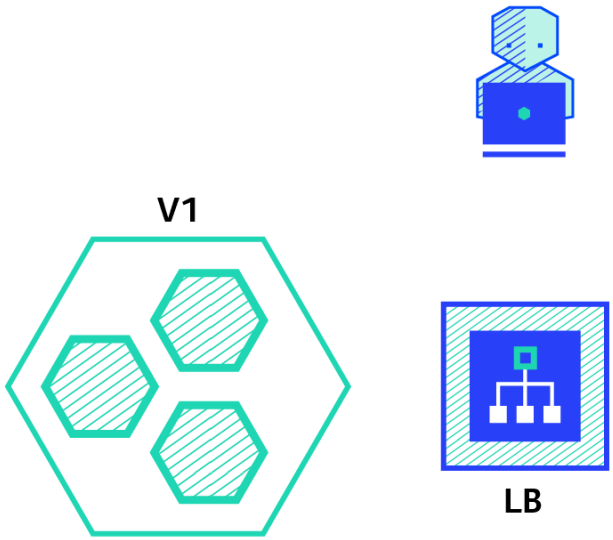

> 金丝雀部署
>
> 矿场。

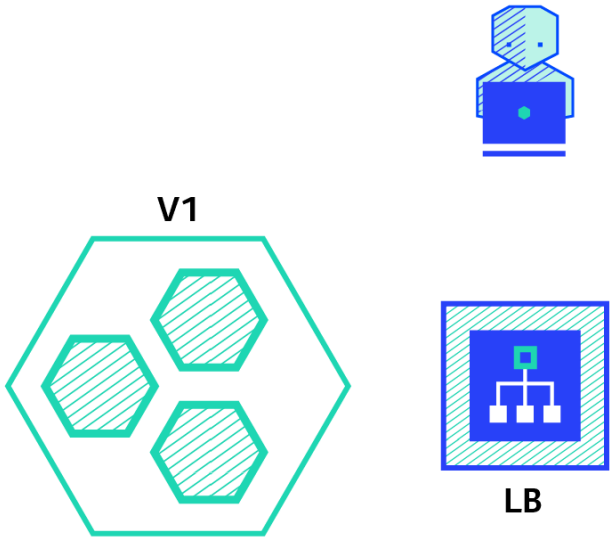

2、金丝雀的简单测试

```
#### 使用这个镜像测试registry.cn-hangzhou.aliyuncs.com/lfy_k8s_images/nginx-test
#### 这个镜像docker run 的时候 -e msg=aaaa，访问这个nginx页面就是看到aaaa
```

步骤原理

- 准备一个Service，负载均衡Pod
- 准备版本v1的deploy，准备版本v2的deploy

滚动发布的缺点？（同时存在两个版本都能接受流量）

- 没法控制流量； 6 4， 8 2 ， 3 7
- 滚动发布短时间就直接结束，不能直接控制新老版本的存活时间。

用两个镜像：

- registry.cn-hangzhou.aliyuncs.com/lfy_k8s_images/nginx-test:env-msg 默认输出11111
- nginx： 默认输出 默认页；

4、 Deployment状态与排错

https://kubernetes.io/zh/docs/concepts/workloads/controllers/deployment/#deployment-status

> kubectl describe 描述一个资源（Pod、Service、Node、Deployment....）来进行排错

Conditions以及Events需要注意

三、RC、RS

RC： ReplicasController：副本控制器

RS：ReplicasSet：副本集；Deployment【滚动更新特性】默认控制的是他

RC是老版，RS是新版（可以有复杂的选择器【表达式】）。

```
      ## RS支持复杂选择器
      matchExpressions:
        - key: pod-name
          value: [aaaa,bbb]
          # In, NotIn, Exists and DoesNotExist
          # In:  value: [aaaa,bbb]必须存在，表示key指定的标签的值是这个集合内的
          # NotIn value: [aaaa,bbb]必须存在，表示key指定的标签的值不是这个集合内的
          # Exists  # 只要有key指定的标签即可，不用管值是多少
          # DoesNotExist  # 只要Pod上没有key指定的标签，不用管值是多少
          operator: DoesNotExist
```

> 虽然ReplicasSet强大，但是我们也不直接写RS；都是直接写Deployment的，Deployment会自动产生RS。
>
> Deployment每次的滚动更新都会产生新的RS。

四、DaemonSet

k8s集群的每个机器(每一个节点)都运行一个程序（默认master除外，master节点默认不会把Pod调度过去）

无需指定副本数量；因为默认给每个机器都部署一个（master除外）

DaemonSet 控制器确保所有（或一部分）的节点都运行了一个指定的 Pod 副本。

- 每当向集群中添加一个节点时，指定的 Pod 副本也将添加到该节点上
- 当节点从集群中移除时，Pod 也就被垃圾回收了
- 删除一个 DaemonSet 可以清理所有由其创建的 Pod

DaemonSet 的典型使用场景有：

- 在每个节点上运行集群的存储守护进程，例如 glusterd、ceph

- 在每个节点上运行日志收集守护进程，例如 fluentd、logstash
- 在每个节点上运行监控守护进程，例如 Prometheus Node Exporter、 Sysdig Agent、collectd、 Dynatrace OneAgent、 APPDynamics Agent、 Datadog agent、 New Relic agent、Ganglia gmond、 Instana Agent 等

```
apiVersion: apps/v1
kind: DaemonSet
metadata:
  name: logging
  labels:
    app: logging
spec:
  selector:
    matchLabels:
      name: logging
  template:
    metadata:
      labels:
        name: logging
    spec:
      containers:
      - name: logging
        image: nginx
        resources:
          limits:
            memory: 200Mi
          requests:
            cpu: 100m
            memory: 200Mi
      tolerations:  #设置容忍master的污点
      - key: node-role.kubernetes.io/master
        effect: NoSchedule
#查看效果
kubectl get pod -l name=logging -o wide
```

五、StatefulSet

> Deployment部署的应用我们一般称为无状态应用
>
> StatefulSet部署的应用我们一般称为有状态应用
>
> 无状态应用：网络可能会变，存储可能会变，顺序可能会变。场景就是业务代码（Deployment）
>
> 有状态应用：网络不变，存储不变，顺序不变。场景就是中间件（MySQL、Redis、MQ）

有状态副本集；Deployment等属于无状态的应用部署（stateless）

- **StatefulSet** 使用场景；对于有如下要求的应用程序，StatefulSet 非常适用：
  - **稳定、唯一的网络标识（dnsname）**【必须配合Service】

        - StatefulSet**通过与其相关的无头服务为每个pod提供DNS解析条目。**假如无头服务的DNS条目为:
          "$(service name).$(namespace).svc.cluster.local",
          那么pod的解析条目就是"$(pod name).$(service name).$(namespace).svc.cluster.local",
          每个pod name也是唯一的。
    - **稳定的、持久的存储；【每个Pod始终对应各自的存储路径（PersistantVolumeClaimTemplate）】**
    - **有序的、优雅的部署和缩放。【按顺序地增加副本、减少副本，并在减少副本时执行清理】**
    - **有序的、自动的滚动更新。【按顺序自动地执行滚动更新】**
- 限制
    - 给定 Pod 的存储必须由 PersistentVolume **驱动** 基于所请求的 `storage class` 来提供，或者由管理员预先提供。
    - 删除或者收缩 StatefulSet 并 *不会* 删除它关联的存储卷。 这样做是为了保证数据安全，它通常比自动清除 StatefulSet 所有相关的资源更有价值。
    - StatefulSet 当前需要 **无头服务** 来负责 Pod 的网络标识。你需要负责创建此服务。
    - 当删除 StatefulSets 时，StatefulSet 不提供任何终止 Pod 的保证。 为了实现 StatefulSet 中的 Pod 可以有序地且体面地终止，可以在删除之前将 StatefulSet 缩放为 0。
    - 在默认 Pod **管理策略**(`OrderedReady`) 时使用 **滚动更新**，可能进入需要 **人工干预** 才能修复的损坏状态。

如果一个应用程序不需要稳定的网络标识，或者不需要按顺序部署、删除、增加副本，**就应该考虑使用 Deployment 这类无状态（stateless）的控制器**

```yaml
apiVersion: v1
kind: Service   #定义一个负载均衡网络
metadata:
  name: stateful-tomcat
  labels:
    app: stateful-tomcat
spec:
  ports:
  - port: 8123
    name: web
    targetPort: 8080
  clusterIP: None   #NodePort：任意机器+NodePort都能访问，ClusterIP：集群内能用这个ip、service域名能访问，clusterIP: None：不要分配集群ip。headless：无头服务。稳定的域名
  selector:
    app: stateful-tomcat
---
apiVersion: apps/v1
kind: StatefulSet  #控制器。
metadata:
  name: stateful-tomcat
spec:
  selector:
    matchLabels:
      app: stateful-tomcat # has to match .spec.template.metadata.labels
  serviceName: "stateful-tomcat" #这里一定注意，必须提前有个service名字叫这个的
  replicas: 3 # by default is 1
  template:
    metadata:
      labels:
        app: stateful-tomcat # has to match .spec.selector.matchLabels
    spec:
```

```
        terminationGracePeriodSeconds: 10
        containers:
        - name: tomcat
          image: tomcat:7
          ports:
          - containerPort: 8080
            name: web

#观察效果。
删除一个，重启后名字，ip等都是一样的。保证了状态


#细节
kubectl explain StatefulSet.spec
podManagementPolicy：
  OrderedReady（按序）、Parallel（并发）

serviceName -required-
  设置服务名，就可以用域名访问pod了。
  pod-specific-string.serviceName.default.svc.cluster.local


#测试
kubectl run -i --tty --image busybox dns-test --restart=Never --rm /bin/sh
ping stateful-tomcat-0.stateful-tomcat

#我们在这里没有加存储卷。如果有的话  kubectl get pvc -l app=stateful-tomcat 我们就能看到即使Pod删了再拉起，卷还是同样的。
```

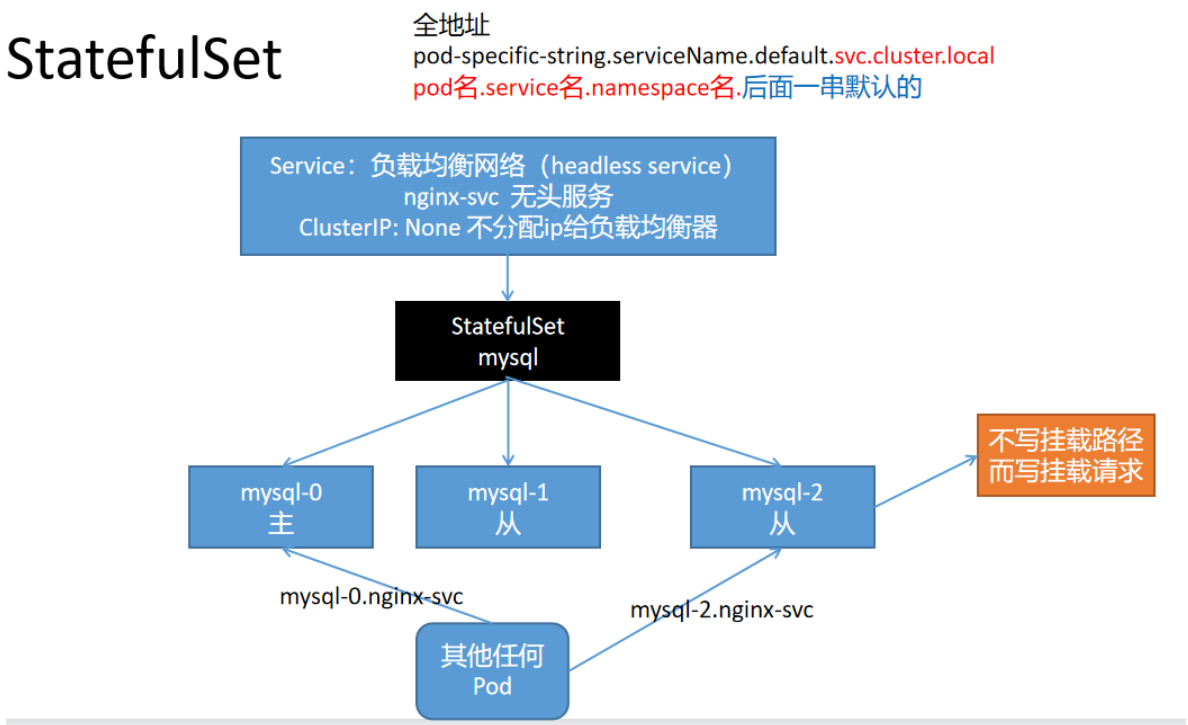

DNS解析。整个状态kubelet（DNS内容同步到Pod）和kube-proxy（整个集群网络负责）会同步

> curl nginx-svc： 负载均衡到sts部署的Pod上
>
> curl mysql-0.nginx-svc： 直接访问指定Pod

1、和Deployment不同的字段

1、podManagementPolicy： pod管理策略

podManagementPolicy ：控制Pod创建、升级以及扩缩容逻辑

podManagementPolicy controls how pods are created during initial scale up, when replacing pods on nodes, or when scaling down. The default policy is `OrderedReady`, where pods are created in increasing order (pod-0, then pod-1, etc) and the controller will wait until each pod is ready before continuing. When scaling down, the pods are removed in the opposite order. The alternative policy is `Parallel` which will create pods in parallel to match the desired scale without waiting, and on scale down will delete all pods at once.

默认是 `OrderedReady`：有序启动

修改为 `Parallel` ： 同时创建启动，一般不用

2、updateStrategy： 更新策略

updateStrategy

updateStrategy indicates the StatefulSetUpdateStrategy that will be employed to update Pods in the StatefulSet when a revision is made to Template.

- rollingUpdate

  RollingUpdate is used to communicate parameters when Type is RollingUpdateStatefulSetStrategyType.

  - partition ： 按分区升级

- type

  Type indicates the type of the StatefulSetUpdateStrategy. Default is RollingUpdate.

实验：

- 先部署一个sts
- ```yaml
  apiVersion: apps/v1
  kind: StatefulSet  ### 有状态副本集
  metadata:
    name: stateful-nginx
    namespace: default
  spec:
    selector:
      matchLabels:
        app: ss-nginx # has to match .spec.template.metadata.labels
    serviceName: "nginx"
  ```
  ```

```
  replicas: 3 # 三个副本
  template: ## Pod模板
    metadata:
      labels:
        app: ss-nginx # has to match .spec.selector.matchLabels
    spec:
      containers:
      - name: nginx
        image: nginx  ## 默认三个开始有序升级
```

- 在进行分区升级

```
apiVersion: apps/v1
kind: StatefulSet  ### 有状态副本集
metadata:
  name: stateful-nginx
  namespace: default
spec:
  podManagementPolicy: OrderedReady  ## 所有Pod一起创建，OrderedReady：有序创建
  updateStrategy: ## 升级策略
    rollingUpdate:
      partition: 1 ### 更新大于等于这个索引的pod
  selector:
    matchLabels:
      app: ss-nginx # has to match .spec.template.metadata.labels
  serviceName: "nginx"
  replicas: 3 # 三个副本
  template: ## Pod模板
    metadata:
      labels:
        app: ss-nginx # has to match .spec.selector.matchLabels
    spec:
      containers:
      - name: nginx
        image: tomcat  ## 默认三个开始有序升级
```

六、Job、CronJob

1、Job

Kubernetes中的 Job 对象将创建一个或多个 Pod，并确保指定数量的 Pod 可以成功执行到进程正常结束：

- 当 Job 创建的 Pod 执行成功并正常结束时，Job 将记录成功结束的 Pod 数量
- 当成功结束的 Pod 达到指定的数量时，Job 将完成执行
- 删除 Job 对象时，将清理掉由 Job 创建的 Pod
- 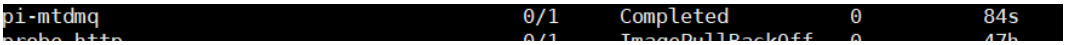


```
apiVersion: batch/v1
kind: Job
```

```
  metadata:
    name: pi
  spec:
    template:
      spec:
        containers:
        - name: pi
          image: perl
          command: ["perl",  "-Mbignum=bpi", "-wle", "print bpi(2000)"]
        restartPolicy: Never #Job情况下，不支持Always
    backoffLimit: 4 #任务4次都没成，认为失败
    activeDeadlineSeconds: 10



  #默认这个任务需要成功执行一次。

  #查看job情况
  kubectl get job

  #修改下面参数设置再试试
  #千万不要用阻塞容器。nginx。job由于Pod一直running状态。下一个永远得不到执行，而且超时了，当前running的Pod还会删掉

   kubectl api-resources
```

```
  #参数说明
  kubectl explain job.spec
      activeDeadlineSeconds：10 总共维持10s
          #该字段限定了 Job 对象在集群中的存活时长，一旦达到 .spec.activeDeadlineSeconds 指定的时长，该 Job 创建的所有的 Pod 都将被终止。但是Job不会删除，Job需要手动删除，或者使用ttl进行清理
      backoffLimit：
          #设定 Job 最大的重试次数。该字段的默认值为 6；一旦重试次数达到了 backoffLimit 中的值，Job 将被标记为失败，且尤其创建的所有 Pod 将被终止；
      completions：  #Job结束需要成功运行的Pods。默认为1
      manualSelector：
      parallelism：  #并行运行的Pod个数，默认为1
      ttlSecondsAfterFinished：   (Time To Live)
          ttlSecondsAfterFinished: 0 #在job执行完时马上删除
          ttlSecondsAfterFinished: 100 #在job执行完后，等待100s再删除
          #除了 CronJob 之外，TTL 机制是另外一种自动清理已结束Job（Completed 或 Finished）的方式：
          #TTL 机制由 TTL 控制器 提供，ttlSecondsAfterFinished 字段可激活该特性
          #当 TTL 控制器清理 Job 时，TTL 控制器将删除 Job 对象，以及由该 Job 创建的所有 Pod 对象。

  # job超时以后 已经完成的不删，正在运行的Pod就删除
  #单个Pod时，Pod成功运行，Job就结束了
  #如果Job中定义了多个容器，则Job的状态将根据所有容器的执行状态来变化。
  #Job任务不建议去运行nginx，tomcat，mysql等阻塞式的，否则这些任务永远完不了。
  ##如果Job定义的容器中存在http server、mysql等长期的容器和一些批处理容器，则Job状态不会发生变化（因为长期运行的容器不会主动结束）。此时可以通过Pod的.status.containerStatuses获取指定容器的运行状态。
```

- manualSelector：

- job同样可以指定selector来关联pod。需要注意的是job目前可以使用两个API组来操作，batch/v1和extensions/v1beta1。当用户需要自定义selector时，使用两种API组时定义的参数有所差异。
- 使用batch/v1时，用户需要将jod的spec.manualSelector设置为true，才可以定制selector。默认为false。
- 使用extensions/v1beta1时，用户不需要额外的操作。因为extensions/v1beta1的spec.autoSelector默认为false，该项与batch/v1的spec.manualSelector含义正好相反。换句话说，使用extensions/v1beta1时，用户不想定制selector时，需要手动将spec.autoSelector设置为true。

```yaml
apiVersion: batch/v1
kind: Job
metadata:
  name: job-test-04
spec:
  completions: 5  ## 前一次必须结束才会下一次
  parallelism: 3
  template:
    spec:
      containers:
      - name: pi
        image: busybox  ## job类型的pod，不要用阻塞式的。如nginx。Deployment才应该是阻塞式的
        command: ["/bin/sh","-c","ping -c 10 baidu.com"]
      restartPolicy: Never #Job情况下，不支持Always
  # backoffLimit: 4 #任务4次都没成，认为失败
  activeDeadlineSeconds: 600     ## 整个Job的存活时间，超出就自动杀死
  ttlSecondsAfterFinished: 10  ### 运行完成后自己删除。结束以后会被自动删除，不指定不删
```

2、CronJob

CronJob创建Job-----Job启动Pod执行命令

CronJob 按照预定的时间计划（schedule）创建 Job（注意：启动的是Job不是Deploy，rs）。一个 CronJob 对象类似于 crontab (cron table) 文件中的一行记录。该对象根据 `Cron` 格式定义的时间计划，周期性地创建 Job 对象。

> Schedule
>
> 所有 CronJob 的 `schedule` 中所定义的时间，都是基于 master 所在时区来进行计算的。

一个 CronJob 在时间计划中的每次执行时刻，都创建 **大约** 一个 Job 对象。这里用到了 **大约** ，是因为在少数情况下会创建两个 Job 对象，或者不创建 Job 对象。尽管 K8S 尽最大的可能性避免这种情况的出现，但是并不能完全杜绝此现象的发生。因此，Job 程序必须是 **幂等的**。1min 执行一次。

当以下两个条件都满足时，Job 将至少运行一次：

- `startingDeadlineSeconds` 被设置为一个较大的值，或者不设置该值（默认值将被采纳）
- `concurrencyPolicy` 被设置为 `Allow`

```
# kubectl explain cronjob.spec

   concurrencyPolicy：并发策略
     "Allow" (允许，default):
     "Forbid"(禁止): forbids：前个任务没执行完，要并发下一个的话，下一个会被跳过
     "Replace"(替换): 新任务，替换当前运行的任务

   failedJobsHistoryLimit：记录失败数的上限，Defaults to 1.
   successfulJobsHistoryLimit： 记录成功任务的上限。 Defaults to 3.
   #指定了 CronJob 应该保留多少个 completed 和 failed 的 Job 记录。将其设置为 0，则 CronJob 不会保留已经结束的 Job 的记录。

   jobTemplate： job怎么定义（与前面我们说的job一样定义法）

   schedule： cron 表达式；

   startingDeadlineSeconds： 表示如果Job因为某种原因无法按调度准时启动，在spec.startingDeadlineSeconds时间段之内，CronJob仍然试图重新启动Job，如果在.spec.startingDeadlineSeconds时间之内没有启动成功，则不再试图重新启动。如果spec.startingDeadlineSeconds的值没有设置，则没有按时启动的任务不会被尝试重新启动。



   suspend  暂停定时任务，对已经执行了的任务，不会生效； Defaults to false.
```

```yaml
apiVersion: batch/v1beta1
kind: CronJob
metadata:
  name: hello
spec:
  schedule: "*/1 * * * *"     #分、时、日、月、周
  jobTemplate:
    spec:
      template:
        spec:
          containers:
          - name: hello
            image: busybox
            args:
            - /bin/sh
            - -c
            - date; echo Hello from the Kubernetes cluster
          restartPolicy: OnFailure
```

```
# ┌──────────────────────── minute (0 - 59)
# │ ┌────────────────────── hour (0 - 23)
# │ │ ┌──────────────────── day of the month (1 - 31)
# │ │ │ ┌────────────────── month (1 - 12)
# │ │ │ │ ┌──────────────── day of the week (0 - 6) (Sunday to Saturday;
# │ │ │ │ │                                 7 is also Sunday on some systems)
# │ │ │ │ │
# │ │ │ │ │
# * * * * * <command to execute>
```

七、GC

https://kubernetes.io/zh/docs/concepts/workloads/controllers/ttlafterfinished/

这是alpha版本

这个特性现在在v1.12版本是alpha阶段，而且默认关闭的，需要手动开启。

- 需要修改的组件包括apiserver、controller还要scheduler。
- apiserver、controller还要scheduler都是以pod的形式运行的，所以直接修改/etc/kubernetes/manifests下面对应的三个.yaml静态文件，加入 `- --feature-gates=TTLAfterFinished=true` 命令，然后重启对应的pod即可。

例如修改后的kube-scheduler.yaml的spec部分如下，kube-apiserver.yaml和kube-controller-manager.yaml也在spec部分加入- --feature-gates=TTLAfterFinished=true即可。

什么是垃圾回收

Kubernetes garbage collector（垃圾回收器）的作用是删除那些曾经有 owner，后来又不再有 owner 的对象。描述

垃圾收集器如何删除从属对象

当删除某个对象时，可以指定该对象的从属对象是否同时被自动删除，这种操作叫做级联删除（cascading deletion）。级联删除有两种模式：后台（background）和前台（foreground）

如果删除对象时不删除自动删除其从属对象，此时，从属对象被认为是孤儿（或孤立的 orphaned）

通过参数 `--cascade`，kubectl delete 命令也可以选择不同的级联删除策略：

- --cascade=true 级联删除
- --cascade=false 不级联删除 orphan

```
#删除rs，但不删除级联Pod
kubectl delete replicaset my-repset --cascade=orphan
```

有些资源没有了 **ownerReferences** 就会被垃圾回收掉